

## 1 Source coding

**Def.** **Source** d'information : v.a.  $X \in \mathcal{X}, |\mathcal{X}| < \infty$  telle que  $X \sim P$  avec probabilités  $\forall i \in \llbracket 1; |\mathcal{X}| \rrbracket, p_i = P(X = i)$ .

**Def.** **Code** pour une source  $X : \mathcal{C} : \mathcal{X} \rightarrow \{0, 1\}^*$ .

**Def.** **Longueur moyenne** d'un code  $\mathcal{C} : \mathcal{L}(\mathcal{C}) = \sum_i p_i l_i$  avec  $l_i$  la longueur du  $i^{\text{e}}$  mot codé.

**Def.** Un code est **non singulier** si  $\forall x_i \neq x_j, \mathcal{C}(x_i) \neq \mathcal{C}(x_j)$ .

**Def.** L'extension d'un code  $\mathcal{C}$  est  $\forall n, \forall x_1, \dots, x_n, \mathcal{C}(x_1, \dots, x_n) \triangleq \mathcal{C}(x_1) * \mathcal{C}(x_2) \cdots * \mathcal{C}(x_n)$ .

**Def.** Un code est à **décodage unique** si son extension est non singulière.

**Def.** Un code est dit **instantané** si aucun mot code n'est le préfixe d'un autre. On dit alors qu'il s'auto-ponctue car on peut décoder en temps réel, symbole par symbole.

**Th (Inégalité de Kraft).** Soit  $\mathcal{C}$  un code instantané avec longueurs  $(l_i)$ . Alors  $\sum_i l_i \leq 1$ . Inversement, soit  $(l_i)$  une famille de longueurs. Si elle satisfait l'inégalité de Kraft alors il existe un code à décodage unique avec ces longueurs.

**Th (de McMillan).** Le théorème précédent reste valable si l'on remplace décodage instantané par décodage unique.

**Cor.**  $\min_{\mathcal{C} \text{ à décodage unique}} \mathcal{L}(\mathcal{C}) = \min_{\mathcal{C} \text{ à décodage instantané}} \mathcal{L}(\mathcal{C})$ .

**Th (Borne entropique).** Pour tout  $\mathcal{C}$  à décodage unique,  $\mathcal{L}(\mathcal{C}) \geq H(X)$ , où  $H(X) = -\sum_i p_i \log_2(p_i)$  est l'entropie de la source, avec égalité si et seulement si  $\forall i, p_i = 2^{-l_i}$ .

**Th (Inégalité de Jensen).** Si  $f$  est convexe, alors  $\mathbf{E}(f(X)) \geq f(\mathbf{E}(X))$ . Si la convexité est stricte alors  $(\mathbf{E}(f(X)) \geq f(\mathbf{E}(X))) \iff (f \text{ est constante})$ .

**Def.** La **divergence de Kullback-Leibler**, ou entropie relative, de deux probabilités  $P$  et  $Q$  est définie par

$$D_{KL}(P\|Q) = \sum_i p_i \log \left( \frac{p_i}{q_i} \right).$$

C'est une mesure de dissimilarité entre les deux distributions de probabilités.

**Cor.** On a  $D_{KL}(P\|Q) \geq 0$  avec égalité si et seulement si  $\forall i, p_i = q_i$ .