

1 Source coding

Soit X une variable aléatoire discrète d'alphabet \mathcal{X} et de fonction de probabilité p telle que $\forall x \in \mathcal{X}, p(x) = \mathbf{P}(X = x)$. On note $p(x)$ plutôt que $p_X(x)$ par commodité, mais par $p(x)$ et $p(y)$ on fait référence à deux fonctions de probabilité distinctes.

Def. X est une **source d'information** si $|\mathcal{X}| < \infty$ et on note $\forall i \in \llbracket 1; |\mathcal{X}| \rrbracket, p_i = p(x_i) = \mathbf{P}(X = x_i)$.

Def. **Code** pour une source $X : \mathcal{C} : \mathcal{X} \rightarrow \{0, 1\}^*$.

Def. **Longueur moyenne** d'un code $\mathcal{C} : \mathcal{L}(\mathcal{C}) = \sum_i p_i l_i$ avec l_i la longueur du i^{e} mot codé.

Def. Un code est **non singulier** si $\forall x_i \neq x_j, \mathcal{C}(x_i) \neq \mathcal{C}(x_j)$.

Def. L'extension d'un code \mathcal{C} est $\forall n, \forall x_1, \dots, x_n, \mathcal{C}(x_1, \dots, x_n) \triangleq \mathcal{C}(x_1) * \mathcal{C}(x_2) \cdots * \mathcal{C}(x_n)$.

Def. Un code est à **décodage unique** si son extension est non singulière.

Def. Un code est dit **instantané** si aucun mot code n'est le préfixe d'un autre. On dit alors qu'il s'auto-ponctue car on peut décoder en temps réel, symbole par symbole.

Th (Inégalité de Kraft). Soit \mathcal{C} un code instantané avec longueurs (l_i) . Alors $\sum_i l_i \leq 1$. Inversement, soit (l_i) une famille de longueurs. Si elle satisfait l'inégalité de Kraft alors il existe un code à décodage unique avec ces longueurs.

Th (de McMillan). Le théorème précédent reste valable si l'on remplace décodage instantané par décodage unique.

Cor. $\min_{\mathcal{C} \text{ à décodage unique}} \mathcal{L}(\mathcal{C}) = \min_{\mathcal{C} \text{ à décodage instantané}} \mathcal{L}(\mathcal{C})$.

Th (Borne entropique). Pour tout \mathcal{C} à décodage unique, $\mathcal{L}(\mathcal{C}) \geq H(X)$, où $H(X) = -\sum_i p_i \log_2(p_i)$ est l'entropie de la source, avec égalité si et seulement si $\forall i, p_i = 2^{-l_i}$.

Th (Inégalité de Jensen). Si f est convexe, alors $\mathbf{E}(f(X)) \geq f(\mathbf{E}(X))$. Si la convexité est stricte alors $(\mathbf{E}(f(X)) \geq f(\mathbf{E}(X))) \iff (f \text{ est constante})$.

Def. La **divergence de Kullback-Leibler**, ou entropie relative, de deux probabilités P et Q est définie par $D_{KL}(P||Q) = \sum_i p_i \log \left(\frac{p_i}{q_i} \right)$.

C'est une mesure de dissimilarité entre les deux distributions de probabilités.

Cor. On a $D_{KL}(P||Q) \geq 0$ avec égalité si et seulement si $\forall i, p_i = q_i$.

Code de Shannon

On construit un code de Shannon en définissant les longueurs selon $l_i = \left\lceil \log \left(\frac{1}{p_i} \right) \right\rceil$, qui satisfait l'inégalité de Kraft et peut donc être utilisé pour produire un code instantané.

Prop. Soit \mathcal{C} un code de Shannon pour X . Alors $H(X) \leq \mathcal{L}(\mathcal{C}) \leq H(X) + 1$.

Codage de Huffman

Pour construire un codage de Huffman on ordonne l'ensemble des p_i , puis l'on construit itérativement de nouveaux ensembles de probabilités en sommant à chaque étape les deux plus faibles. On repart ensuite à l'inverse : à partir de la dernière probabilité, égale à 1, on va re-diviser les probabilités de sorte à construire un arbre dont les feuilles correspondront aux p_i . La profondeur de chaque feuille i s'identifie alors à l_i .

Th. Un code de Huffman minimise $\mathcal{L}(\mathcal{C})$.

2 Entropie et questionnement

On remarque que $\mathcal{L}(\mathcal{C})$ s'identifie au nombre moyen de questions à poser pour identifier une valeur $X \in \mathcal{X}$.

Def (...).

Th. On a $0 \leq H(X) \leq \log(|\mathcal{X}|)$.

Def. Soit $(X, Y) \sim p(x, y)$. On a $H(X, Y) = -\sum_{x,y} p(x, y) \log(p(x, y)) = -\mathbf{E}_{p(x,y)}(\log(p(X, Y)))$. Et pour des v.a. X_1, \dots, X_n il vient $H(X_1, \dots, X_n) = -\mathbf{E}_{p(x_1, \dots, x_n)}(\log(p(X_1, \dots, X_n)))$.

Def (Entropie conditionnelle). $H(Y | X) = \sum_x p(x) H(Y | X = x) = -\sum_{x,y} p(x, y) \log(p(y | x)) = -\mathbf{E}[\log(p(Y | X))]$

Th (Chain rule). $H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X^{i-1})$ où $X^i \triangleq X_1, \dots, X_i$.

Prop. L'information mutuelle $I(X; Y) = \sum_{x,y} p(x, y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right)$ vérifie

- $I(X; Y) = H(X) + H(Y) - H(X, Y)$
- $I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X) = I(Y; X)$
- $I(X; X) = H(X)$
- $I(X; Y) = D_{KL}(p_{X,Y} || p_X \cdot p_Y)$

- $I(X; Y) = 0 \iff X \perp\!\!\!\perp Y$
- $H(Y | X) \leq H(Y)$
- $H(X^n) \leq \sum_{i=1}^n H(X_i)$
- $H(X)$ est concave en p_X
- $H(f(X)) \leq H(X)$ pour toute fonction f déterministe.

Def. On définit $H(X; Y | Z) = \sum_{x,y,z} p(x, y, z) \log \left(\frac{p(x,y|z)}{p(x|z)p(y|z)} \right) = H(X | Z) - H(X | Y, Z)$.

Th. $I(X_1, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y | X^{i-1})$.

Def. Soit X_1, \dots, X_n i.i.d.. On appelle $A_\varepsilon^n = \{x^n \mid 2^{-n(H(x)+\varepsilon)} \leq p(x^n) \leq 2^{-n(H(x)-\varepsilon)}\}$ **ensemble typique**.

Th.

- Pour n suffisamment grand, $\mathbf{P}(A_\varepsilon^n) \geq 1 - \varepsilon$.
- $(1 - \varepsilon)2^{-n(H(x)-\varepsilon)} \leq |A_\varepsilon^n| \leq 2^{-n(H(x)+\varepsilon)}$

