

## 1 Convergence de variables aléatoires

### Calcul sur les événements

**Prop.** • Si  $(A_n)_n$  est croissante,  $\mathbf{P}(\bigcup_n A_n) = \lim_{n \rightarrow \infty} \mathbf{P}(A_n)$ .  
 • Si  $(A_n)_n$  est décroissante,  $\mathbf{P}(\bigcap_n A_n) = \lim_{n \rightarrow \infty} \mathbf{P}(A_n)$ .  
 • Si  $\forall n, \mathbf{P}(A_n) = 0$  alors  $\mathbf{P}(\bigcup_n A_n) = 0$ .  
 • Si  $\forall n, \mathbf{P}(A_n) = 1$  alors  $\mathbf{P}(\bigcap_n A_n) = 1$ .

**Def.**  $\limsup_{n \rightarrow \infty} A_n = \bigcap_{n \in \mathbb{N}} \bigcup_{k \geq n} A_k$ , i.e.  $\omega \in \limsup_{n \rightarrow \infty} A_n \iff \forall n, \exists k \geq n, \omega \in A_k$ .  
 Donc  $\limsup_{n \rightarrow \infty} A_n$  est réalisé ssi une infinité de  $A_n$  est réalisé.

**Lem** (de Borel-Cantelli). Si  $\sum_n \mathbf{P}(A_n) < \infty$ , alors  $\mathbf{P}(\limsup_{n \rightarrow \infty} A_n) = 0$ .

Autrement dit, il y a une proba 1 pour que seulement un nombre fini de  $A_n$  soient réalisés.

### Convergence p.s., en probabilité et dans $L^p$

**Def.** (i) On dit que  $X_n \xrightarrow{\mathbf{P}} X$  (**converge en probabilité**) si  $\forall \epsilon > 0, \mathbf{P}(\|X_n - X\| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$ .

(ii) On dit que  $X_n \xrightarrow{\text{p.s.}} X$  (**converge presque sûrement**), si  $\forall \omega$   $\mathbf{P}$ -p.p,  $X_n(\omega) \rightarrow X(\omega)$ . Autrement dit il existe  $A \in \mathcal{F}$  tel que  $\mathbf{P}(A) = 1$  et  $\forall \omega \in A, \lim_n X_n(\omega) = X(\omega)$ .

(iii) On dit que  $X_n \xrightarrow{L^p} X$  (**converge vers  $X$  dans  $L^p(\Omega, \mathbf{R}^d)$** ) si  $X_n, X \in L^p$  et  $\mathbf{E}(\|X_n - X\|^p) \xrightarrow{n \rightarrow \infty} 0$ .

**Prop.** On note  $X_n = (X_n^{(1)}, \dots, X_n^{(d)})$  sur  $\mathcal{X} = \mathbf{R}^d$ . Alors  $X_n \xrightarrow{\text{p.s.}} X$  p.s. (resp. en probabilité, dans  $L^p$ ) ssi  $\forall k \in \llbracket 1; d \rrbracket, X_n^{(k)} \xrightarrow{\text{p.s.}} X^{(k)}$  (resp. en probabilité, dans  $L^p$ ).

**Prop.** Si  $X_n \xrightarrow{\text{p.s.}} X$  ou  $X_n \xrightarrow{L^p} X$  alors  $X_n \xrightarrow{\mathbf{P}} X$ .

**Prop.** Si  $\forall \epsilon > 0, \sum_n \mathbf{P}(\|X_n - X\| > \epsilon) < \infty$  alors  $X_n \xrightarrow{\text{p.s.}} X$ .

**Prop.**  $X_n \xrightarrow{\mathbf{P}} X$  ssi de toute sous-suite  $X_{\varphi(n)}$  on peut extraire une autre sous-suite  $X_{\varphi \circ \psi(n)}$  telle que  $X_{\varphi \circ \psi(n)} \xrightarrow{\text{p.s.}} X$ .

**Th** (de continuité). Soit  $h: \mathbf{R}^d \rightarrow \mathbf{R}^p$  mesurable et continue sur  $C \in \mathcal{B}(\mathbf{R}^d)$  tel que  $\mathbf{P}(X \in C) = 1$  :

(i) Si  $X_n \xrightarrow{\text{p.s.}} X$  alors  $h \circ X_n \xrightarrow{\text{p.s.}} h \circ X$

(ii) Si  $X_n \xrightarrow{\mathbf{P}} X$  alors  $h \circ X_n \xrightarrow{\mathbf{P}} h \circ X$ .

**Th** (Loi forte des grands nombres). Soit  $(X_n)$  i.i.d. telle que  $\mathbf{E}(\|X_1\|) < \infty$ . Alors  $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{p.s.}} \mathbf{E}(X_1)$ .

**Th** (Loi faible des grands nombres). Soit  $(X_n)$  i.i.d. telle que  $\mathbf{E}(\|X_1\|^2) < \infty$ . On a  $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbf{P}} \mathbf{E}(X_1)$ .

## 2 Convergence en loi

### Définitions et propriétés

**Def.** Une mesure de proba  $\mu$  sur  $(\mathbf{R}^d, \mathcal{B}(\mathbf{R}^d))$  est caractérisée par sa **fonction de répartition**

$$F_\mu: (x_1, \dots, x_d) \mapsto \mu \left( \prod_i ]-\infty; x_i] \right).$$

**Prop.** •  $F_\mu$  croissante.

•  $F_\mu(-\infty) = 0, F_\mu(+\infty) = 1$

•  $F_\mu$  est continue à droite et  $\mu(x_0) = F_\mu(x_0) - F_\mu(x_0^-)$

**Th.** Deux mesures distinctes ne peuvent pas avoir la même fonction de répartition.

Soit  $X: \Omega \rightarrow \mathbf{R}^d$  une v.a. On note  $P_X = \mathbf{P} \circ X^{-1}$  la loi de  $X$ .  $P_X$  est une mesure de proba sur  $\mathbf{R}^d$ . On note  $F_X$  sa fonction de répartition. Pour  $d = 1, F_X(x) = \mathbf{P}(X \leq x)$ .

**Def.** Soit  $(\mu_n)_n, \mu$  des mesures de proba sur  $\mathbf{R}^d$ . On dit que  $\mu_n$  **converge faiblement (ou étroitement)** vers  $\mu$  si  $\lim_n F_{\mu_n}(x) = F_\mu(x)$  en tout  $x$  point de continuité de  $F_\mu$ . On note  $\mu_n \Rightarrow \mu$ .

**Def.**  $(X_n)_n, X$  v.a. sur  $\mathbf{R}^d$ . On dit que  $X_n$  **converge en loi** vers  $X$  (noté  $X_n \xrightarrow{\mathcal{L}} X$ ) si  $P_{X_n} \Rightarrow P_X$ .

**Prop.** Si  $X_n \xrightarrow{\mathbf{P}} X$  alors  $X_n \xrightarrow{\mathcal{L}} X$ .

**Th** (de représentation de Skorohod). Soit  $(\mu_n)_n, \mu$  des mesures de proba sur  $\mathbf{R}^d$  telles que  $\mu_n \Rightarrow \mu$ . Il existe un espace de proba et des v.a.  $(Y_n), Y$  sur cet espace à valeurs dans  $(\mathbf{R}^d, \mathcal{B}(\mathbf{R}^d))$  telles que  $Y \sim \mu, \forall n, Y_n \sim \mu_n$  et  $Y$  est limite simple des  $Y_n$ , i.e.  $\forall \omega, Y_n(\omega) \rightarrow Y(\omega)$ .

**Th** (de continuité). Soit  $h: \mathbf{R}^d \rightarrow \mathbf{R}^p$  mesurable et continue sur  $C \in \mathcal{B}(\mathbf{R}^d)$  tel que  $\mathbf{P}(X \in C) = 1$ . Si  $X_n \xrightarrow{\mathcal{L}} X$  alors  $h \circ X_n \xrightarrow{\mathcal{L}} h \circ X$ .

**Th.** Les affirmations suivantes sont équivalentes :

- (i)  $\mu_n \Rightarrow \mu$ ,
- (ii) pour toute fonction  $f$  continue,  $\mu_n(f) \rightarrow \mu(f)$ ,
- (iii) pour toute fonction  $f$  lipschitzienne,  $\mu_n(f) \rightarrow \mu(f)$ ,
- (iv) pour tout  $A \in \mathcal{B}(\mathbf{R}^d)$  tel que  $\mu(\delta A) = 0$  (frontière de  $A$ ),  $\mu_n(A) \rightarrow \mu(A)$ .

**Th** (de Portmanteau). On a équivalence entre :

- (i)  $X_n \xrightarrow{\mathcal{L}} X$ ,
- (ii)  $\forall f: \mathbf{R}^d \rightarrow \mathbf{R}$  continue bornée,  $\mathbf{E}(f(X_n)) \rightarrow \mathbf{E}(f(X))$ ,
- (iii)  $\forall A \subset \mathbf{R}^d$  tel que  $\mathbf{P}(X \in \delta A) = 0$ , on a  $\mathbf{P}(X_n \in A) \rightarrow \mathbf{P}(X \in A)$  où  $\delta A = \bar{A} \setminus \overset{\circ}{A}$ ,
- (iv)  $\forall t \in \mathbf{R}^d$ ,  $\lim_n \phi_{X_n}(t) = \phi_X(t)$ .

**Th.** Soit  $m \in \mathbf{N}^*$  et  $h: \mathbf{R}^d \rightarrow \mathbf{R}^p$  mesurable et continue sur  $C \in \mathcal{B}(\mathbf{R}^d)$  tel que  $\mathbf{P}(X \in C) = 1$ . Si  $\mu_n \Rightarrow \mu$  alors  $\mu_n h^{-1} \Rightarrow \mu h^{-1}$ .

**Th** (Procédé de Cramer-Wold). Soit  $X_n, X$  des v.a. sur  $\mathbf{R}^d$ . On a  $X_n \xrightarrow{\mathcal{L}} X \iff \forall t, \langle t | X_n \rangle \xrightarrow{\mathcal{L}} \langle t | X \rangle$ .

### Mesures tendues

**Lem** (d'Helly). Soit  $(F_n)_n$  une suite de fonctions de répartition. Il existe une sous-suite  $(\varphi(n))_n$  et  $F: \mathbf{R} \rightarrow [0; 1]$  croissante, continue à droite, telle que  $\lim_n F_{\varphi(n)}(x) = F(x)$  en tout  $x$  point de continuité de  $F$ .

On ajoute une condition pour que la limite vérifie  $\lim_{x \rightarrow -\infty} F(x) = 0$  et  $\lim_{x \rightarrow +\infty} F(x) = 1$ .

**Def.**  $(\mu_n)_n$  est dite **tendue** si  $\forall \varepsilon > 0, \exists \mathcal{K}$  compact,  $\forall n, \mu_n(\mathcal{K}) \geq 1 - \varepsilon$ .

Dans le cas  $d = 1$  on peut prendre  $\mathcal{K} = [-K; K]$ .

**Def.**  $(X_n)_n$  est **tendue** si  $\forall \varepsilon > 0, \exists \mathcal{K}$  compact,  $\forall n, \mathbf{P}(X_n \in \mathcal{K}) \geq 1 - \varepsilon$ .

**Prop.** (i) Toute famille finie de mesures de probabilité est tendue.

(ii) Une suite de mesures qui converge faiblement est tendue.

**Th** (de Prokhorov). Soit une famille  $\mathcal{M}$  de mesures de probabilité. Alors  $\mathcal{M}$  est tendue si et seulement si elle est relativement séquentiellement compacte pour la topologie de la convergence faible, i.e. de toute suite  $(\mu_n)_n$  de  $\mathcal{M}$  on peut extraire une sous suite  $(\mu_{\varphi(n)})_n$  telle que  $\mu_{\varphi(n)} \Rightarrow \mu$  avec  $\mu$  une mesure de probabilité.

**Prop.** Soit  $(\mu_n)_n$  tendue. Si toute sous-suite faiblement convergente de  $(\mu_n)_n$  converge vers  $\mu$ , alors  $\mu_n \Rightarrow \mu$ .

### Fonction caractéristique

**Def.** La fonction caractéristique d'une mesure de proba  $\mu$  sur  $\mathbf{R}^d$  est  $\phi_\mu: \begin{matrix} \mathbf{R}^d & \rightarrow & \mathbf{C} \\ t & \mapsto & \int e^{i\langle t|x \rangle} d\mu(x) \end{matrix}$ .

**Th.**  $\varphi_\mu = \varphi_\nu \implies \mu = \nu$ .

**Prop.** Soit  $\mu$  une mesure sur  $\mathbf{R}$  et  $p \in \mathbf{N}$  tel que  $\int |x|^p d\mu(x) < \infty$ . Alors  $\phi_\mu$  est  $p$  fois continument dérivable et  $\forall t \in \mathbf{R}$ , sa  $p^e$  dérivée satisfait  $\forall t \in \mathbf{R}, \phi_\mu^{(p)} = \int i^p x^p e^{itx} d\mu(x)$ .

**Ex.**  $\forall t \in \mathbf{R}, \phi_{\mathcal{N}(0,1)}(t) = e^{-t^2/2}$ .

**Prop.** Pour  $Y = AX + b$  on a  $\forall t, \phi_Y(t) = e^{i\langle t|b \rangle} \phi_X(A^*t)$ .

**Prop.**  $\phi_\mu$  est continue en zéro.

**Th** (de Lévy). Soit  $(\mu_n)_n, \mu$  des mesures de probabilité sur  $\mathbf{R}^d$ .  $\mu_n \Rightarrow \mu$  ssi  $\forall t \in \mathbf{R}^d, \phi_{\mu_n}(t) \rightarrow \phi_\mu(t)$ .

### Théorème centrale limite

**Not.**  $\mathcal{N}(m, \sigma^2)$  désigne la loi de densité  $\rho(x) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-m)^2}{2\sigma^2}}$ , et si  $\sigma^2 = 0$  c'est la loi  $\delta_m$ .

Pour  $X$  gaussien, sa fonction caractéristique vérifie  $\phi_X(t) = e^{i\langle t|m \rangle} e^{-\frac{1}{2}\langle t|\Sigma t \rangle}$  où  $m = \mathbf{E}(X)$  et  $\Sigma = \text{Cov}(X)$ .

**Th** (central limite). Soit  $(X_n)_n$  iid tel que  $\mathbf{E}(\|X_1\|^2) < \infty$ . Alors

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mathbf{E}(X_1)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \text{Cov}(X_1)).$$

**Th** (de Linderbergh). Soit un tableau de v.a.  $(X_{i,n})_{1 \leq i \leq n}$  tel que

- $\forall n$ , les v.a.  $X_{1,n}, \dots, X_{n,n}$  sont indépendantes,
- $\forall n, \forall i \leq n, \mathbf{E}(X_{i,n}) = 0$ ,
- $\exists \Sigma, \lim_n \sum_{i=1}^n \text{Cov}(X_{i,n}) = \Sigma$
- $\forall \varepsilon > 0, \lim_n \sum_{i=1}^n \mathbf{E}(\|X_{i,1}\|^2 \mathbf{1}_{\|X_{i,n}\| > \varepsilon}) = 0$  (condition de Lindebergh).

Alors  $\sum_{i=1}^n X_{i,n} \xrightarrow{\mathcal{L}} \mathcal{N}(0, \Sigma)$ .

**Lem.** Soit  $\mathcal{U} := \{z \in \mathbb{C} \mid |z| \leq 1\}$ ,  $n \in \mathbb{N}^*$  et deux familles  $(z_i)_{1 \leq i \leq n}$  et  $(w_i)_{1 \leq i \leq n}$  de  $\mathcal{U}$ . Alors  $|\prod_{i=1}^n z_i - \prod_{i=1}^n w_i| \leq \sum_{i=1}^n |z_i - w_i|$ .

### 3 Manipulation des convergences

Quelques règles

**Prop.** (i)  $\forall a \in \mathbb{R}^d, X_n \xrightarrow{\mathcal{L}} a \iff X_n \xrightarrow{\mathbf{P}} a$

(ii)  $\left. \begin{array}{l} X_n \xrightarrow{\mathcal{L}} X \\ Y_n - X_n \xrightarrow{\mathcal{L}} 0 \end{array} \right\} \implies Y_n \xrightarrow{\mathcal{L}} X$

(iii)  $\forall a \in \mathcal{Y}, \left. \begin{array}{l} X_n \xrightarrow{\mathcal{L}} X \\ Y_n \xrightarrow{\mathcal{L}} a \end{array} \right\} \implies (X_n, Y_n) \xrightarrow{\mathcal{L}} (X, a)$

(iv)  $\left. \begin{array}{l} X_n \xrightarrow{\mathbf{P}} X \\ Y_n \xrightarrow{\mathbf{P}} c \end{array} \right\} \implies (X_n, Y_n) \xrightarrow{\mathbf{P}} (X, c)$

**Notation**  $o_P, O_P$

**Not.** • On dit que  $X_n = o_P(1)$  si  $X_n \xrightarrow{\mathbf{P}} 0$ .

- On dit que  $X_n = o_P(Y_n)$  si  $\exists (Z_n) \xrightarrow{\mathbf{P}} 0, X_n = Z_n Y_n$ .
- On dit que  $X_n = O_P(1)$  si  $(X_n)$  est borné en probabilité, i.e.  $(X_n)$  est tendue.
- On dit que  $X_n = O_P(Y_n)$  si  $\exists (Z_n) = O_P(1), X_n = Z_n Y_n$ .

**Prop.** Si  $X_n \xrightarrow{\mathcal{L}} X$  alors  $X_n = O_P(1)$ .

**Prop.** (i)  $o_P(1) + O_P(1) = O_P(1)$ ,

(ii)  $o_P(1) \cdot O_P(1) = o_P(1)$ ,

(iii)  $o_P(1) + o_P(1) = o_P(1)$ ,

(iv)  $\frac{1}{1+o_P(1)} = O_P(1)$ .

**Lem (de Slutsky).** Soit  $(X_n)_n$  et  $(Y_n)_n$  tels que  $X_n \xrightarrow{\mathcal{L}} X$  et  $Y_n \xrightarrow{\mathcal{L}} a$  :

- (i) Pour  $a \in \mathcal{X}$  quelconque,  $X_n + Y_n \xrightarrow{\mathcal{L}} X + a$ .
- (ii) Dans le cas réel  $a \in \mathbb{R}$ ,  $X_n Y_n \xrightarrow{\mathcal{L}} aX$  et  $\frac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \frac{X}{a}$  si  $a \neq 0$ .

**Delta-méthode**

Soit  $g: \mathbb{R}^d \rightarrow \mathbb{R}^m$  dérivable en un point  $\nu \in \mathbb{R}^d$  de matrice jacobienne  $\nabla g(\nu)$ .

Rappel :  $\lim_{h \rightarrow 0} \frac{\|g(\nu+h) - g(\nu) - \nabla g(\nu) \cdot h\|}{\|h\|} = 0, \nabla g(\nu) = \left( \frac{\partial g_i(\nu)}{\partial \nu_j} \right)_{i \in \llbracket 1; d \rrbracket, j \in \llbracket 1; m \rrbracket}$ .

**Th.** Soit  $g: \mathbb{R}^d \rightarrow \mathbb{R}^m$  dérivable en  $\nu$ . Soient  $T_n, T$  des v.a. sur  $\mathbb{R}^d$  et  $(r_n)$  une suite réelle telle que  $\lim_n r_n = +\infty$  et  $r_n(T_n - \nu) \xrightarrow{\mathcal{L}} T$ . Alors  $r_n(g(T_n) - g(\nu)) \xrightarrow{\mathcal{L}} \nabla g(\nu) \cdot T$ .

### 4 Statistique asymptotique

**Not.** •  $(\Omega, \mathcal{F}, \mathbf{P})$  espace de proba,

- $(X_i)_{i \in \mathbb{N}}$  v.a. iid
- $\forall i \in \mathbb{N}, X_i = (X_i^{(1)}, \dots, X_i^{(d)})^\top$ ,
- $\|\cdot\|$  norme euclidienne.

**Introduction**

**Def.** Un **estimateur**  $\hat{\theta}_n$  à valeurs dans  $\Theta \subset \mathbb{R}^q$  est une transformation mesurable de  $(X_1, \dots, X_n)$ .

- $\hat{\theta}_n$  est **faiblement consistant** si  $\hat{\theta}_n \xrightarrow{\mathbf{P}} \theta_0$ .
- $\hat{\theta}_n$  est **fortement consistant** si  $\hat{\theta}_n \xrightarrow{\text{p.s.}} \theta_0$ .
- $\hat{\theta}_n$  est **asymptotiquement normal** si  $\sqrt{n}(\hat{\theta}_n - \theta_0) \implies \mathcal{N}(0, \sigma_0^2)$  avec  $\sigma_0^2 > 0$ .

**Rem.** La consistance est différente du biais. En effet, soit  $\bar{X}^n = \frac{1}{n} \sum_{i=1}^n X_i, \hat{\theta}_n = \bar{X}^n + \frac{1}{n}$  est fortement consistant (si  $\mathbf{E}(X_1) < \infty$ ) et biaisé car  $\mathbf{E}(\hat{\theta}_n) - \mathbf{E}(X_1) = \frac{1}{n}$ .

À l'inverse  $\hat{\theta}_n = X_1$  est sans biais mais non consistant.

**Def.** Soit  $\Theta \subset \mathbb{R}^q$ .

- $\hat{\theta}_n$  est un **M-estimateur** si  $\hat{\theta}_n \in \arg \min_{\theta \in \Theta} M(\theta)$ .
- $\hat{\theta}_n$  est un **Z-estimateur** si  $\Psi_n(\hat{\theta}_n) = 0$ .

- Ex.**
- Moindres carrés :  $\hat{\beta}_n$  est défini par  $\hat{\beta}_n = \arg \min_{\beta \in \mathbf{R}^d} \sum_{i=1}^n (Y_i - X_i^\top \beta)^2$ .
  - Maximum de vraisemblance : soit la famille paramétrique  $\mathcal{P} = \{f_\theta \mid \theta \in \Theta\}$  selon laquelle sont distribuées les données  $(X_1, \dots, X_n)$ .

$$\hat{\theta}_n = \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log(f_\theta(X_i))$$

- Estimateur des moments par rapport à  $\mathcal{P} = \{\mathbf{P}_\theta \mid \theta \in \Theta\}$  et  $g: \mathcal{X} \rightarrow \mathbf{R}^p$  :  $\hat{\theta}_n$  est pris tel que

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = \int g d\mathbf{P}_{\hat{\theta}_n} = \mathbf{E}_{\hat{\theta}_n}(g(X_1)) .$$

- Estimateur des moments généralisés GMM (si pas de solution avec le précédent) :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \left\| \frac{1}{n} \sum_{i=1}^n g(X_i) - \int g d\mathbf{P}_\theta \right\| .$$

**Rem.** Un Z-estimateur est toujours un M-estimateur car  $\forall \theta \in \Theta, 0 = \|\Psi_n(\hat{\theta}_n)\| \leq \|\Psi_n(\theta)\|$ . Un M-estimateur est un Z-estimateur si  $M_n$  est continuellement dérivable sur  $\Theta$  et  $\hat{\theta}_n$  est un point intérieur à  $\Theta$ . Alors  $\nabla M_n(\hat{\theta}_n) = 0$ .

**Prop (Consistance M-estimateur).** Si  $\hat{\theta}_n$  est un M-estimateur et que

- $\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{\mathbf{P} \text{ resp. p.s.}} 0$  (convergence uniforme)
- $\forall \varepsilon > 0, \inf_{\theta \in \Theta \setminus B(\theta_0, \varepsilon)} M(\theta) > M(\theta_0)$

alors  $\hat{\theta}_n \xrightarrow{\mathbf{P} \text{ resp. p.s.}} \theta_0$ .

**Prop (Consistance Z-estimateur).** Si  $\hat{\theta}_n$  est un Z-estimateur et

- $\sup_{\theta \in \Theta} \|\Psi_n(\theta) - \Psi(\theta)\| \xrightarrow{\mathbf{P} \text{ resp. p.s.}} 0$ ,
- $\forall \varepsilon > 0, \inf_{\theta \in \Theta \setminus B(\theta_0, \varepsilon)} \|\Psi(\theta)\| > \|\Psi(\theta_0)\|$ ,

alors  $\hat{\theta}_n \xrightarrow{\mathbf{P} \text{ resp. p.s.}} \theta_0$ .

En pratique on doit vérifier les 2 hypothèses des résultats précédents. Souvent  $M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \rho(X_i, \theta)$  et  $\Psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n \Psi(X_i, \theta)$ .

**Lem.** Soit  $\Theta$  compact. Supposons

- $\forall \theta \in \Theta, \mathbf{E}(|\rho(X_1, \theta)|) < \infty$ ,
- $\exists r: \mathcal{X} \rightarrow \mathbf{R}_+$  tel que  $\mathbf{E}(r(X_1)) < \infty$  et  $\forall (\theta, \theta') \in \Theta^2, \forall x \in \mathcal{X}, |\rho(x, \theta) - \rho(x, \theta')| \leq r(x) \|\theta - \theta'\|$ ,

alors  $\sup_{\theta \in \Theta} \left| \frac{1}{n} \sum_{i=1}^n \rho(X_i, \theta) - \mathbf{E}[\rho(X_1, \theta)] \right| \xrightarrow{\text{p.s.}} 0$ .

**Lem (Vérification de la condition d'identifiabilité).** Soit  $\Theta \subset \mathbf{R}^q$  compact et  $M \in \mathcal{C}^0(\Theta)$  telle que  $\theta_0$  en est l'unique maximum. Alors  $\forall \varepsilon > 0, \inf_{\theta \in \Theta \setminus B(\theta_0, \varepsilon)} M(\theta) > M(\theta_0)$ .

On peut ainsi facilement vérifier les conditions de la propriété de consistance.

**Prop.** Soit  $\Theta$  compact. Supposons  $\mathbf{E}_{\theta_0}(\|g\|) < +\infty$  et  $\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \left\| \frac{1}{n} \sum_{i=1}^n g(X_i) - \mathbf{E}_{\theta} g \right\|$ . Si, de plus,  $\theta \mapsto \mathbf{E}_{\theta} g$  est injective et continue alors  $\hat{\theta}_n \xrightarrow{\text{p.s.}} \theta_0$ .

### Normalité asymptotique

On considère ici uniquement les Z-estimateurs :  $\frac{1}{n} \sum_{i=1}^n \psi(X_i, \hat{\theta}_n) = \Psi_n(\hat{\theta}_n) = 0$ .

**Th.** Supposons que :

- $\hat{\theta}_n \xrightarrow{\mathbf{P}} \theta$ ,
- il existe un voisinage  $v(\theta_0)$  tel que  $\forall x \in \mathcal{X}, \theta \mapsto \psi(x, \theta)$  est  $\mathcal{C}^2$  sur  $v(\theta_0)$  et  $\forall k \in \llbracket 1; q \rrbracket, \mathbf{E} \left[ \sum_{\theta \in v(\theta_0)} \|\psi_k(X_1, \theta)\| \right] < +\infty$ ,
- soit  $\Phi: (x, \theta) \mapsto \begin{pmatrix} \nabla_{\theta} \psi_1(x, \theta) \\ \vdots \\ \nabla_{\theta} \psi_q(x, \theta) \end{pmatrix} \in \mathbf{R}^{q \times q}$  tel que  $\mathbf{E}[\|\Phi(X_1, \theta_0)\|] < +\infty$  et  $\mathbf{E}[\Phi(X_1, \theta_0)] = Q(\theta_0)$  est inversible,
- $\mathbf{E}[\|\psi(X_1, \theta_0)\|^2] < +\infty$ .

Alors  $\sqrt{n}(\hat{\theta}_n - \theta_0) = -Q(\theta_0)^{-1} \left( \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi(X_i, \theta_0) \right) + o_P(1)$ . En particulier

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{\mathcal{L}} \mathcal{N} \left( 0, Q(\theta_0)^{-1} \text{Var}(\psi(X_1, \theta_0)) (Q(\theta_0)^{-1})^\top \right) .$$