

MACS205 : Méthode de Monte-Carlo

1 Introduction

But du cours : étudier des méthodes aléatoires d'approximation d'intégrales.

Soit (S, \mathcal{S}, μ) un espace mesuré où μ est une mesure positive. Soit $\varphi: S \rightarrow \mathbf{R}$ une fonction intégrable. On cherche à approcher $I(\varphi) = \int \varphi d\mu$.

Plusieurs cas de figure en pratique :

- φ est une fonction continue avec une expression analytique et on arrive à calculer son intégrale,
- l'intégrale de φ est incalculable. Exemples : Gaussienne ou indicatrice d'ensemble S où l'on ne connaît pas de forme analytique.

Les méthodes considérées sont de la forme suivante :

1. choisir/tirer des points X_1, \dots, X_n sur S ,
2. évaluer $\varphi(X_1), \dots, \varphi(X_n)$,
3. trouver une transformation de $(X_1, \varphi(X_1)), \dots, (X_n, \varphi(X_n))$ qui approche $I(\varphi)$.

2 La méthode de Monte-Carlo

$$I(\varphi) = \int \varphi dN = \mathbf{E}_\mu(\varphi)$$

D'après la LFGN, si X_1, \dots, X_n sont i.i.d. de loi μ tel que $\mathbf{E}_\mu |vf| < \infty$ alors $\frac{1}{n} \sum_i \varphi(X_i) \xrightarrow{\text{p.s.}} \mathbf{E}_\mu(\varphi(X_1))$.

Algorithme 1 : Monte-Carlo

Générer X_1, \dots, X_n de façon indépendante sous μ ;

Calculer $\varphi(X_1), \dots, \varphi(X_n)$;

Sorties : $\hat{I}_n(\varphi) = \frac{1}{n} \sum_i \varphi(X_i)$

Prop. Si $\int |\varphi| d\mu < \infty$, $\hat{I}_n(\varphi)$ est non-biaisée et consistante. Si $\int |\varphi|^2 d\mu < \infty$, $\text{Var}(\hat{I}_n(\varphi)) = \frac{1}{n} \text{Var}(\varphi(X_1)) = \frac{1}{n} \sigma^2$ et $\sqrt{n}(\hat{I}_n(\varphi) - I(\varphi)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

On estime σ^2 par $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (\varphi(X_i) - \hat{I}_n(\varphi))^2$.

Prop. Si $\int |\varphi|^2 d\mu < \infty$ alors $\hat{\sigma}^2$ est sans biais et fortement consistant (par la LFGN).

...

Th (Inégalité de Hoeffding). Soit (X_1, \dots, X_n) des v.a i.i.d telles que $\forall i \in [1; n], a \leq X_i \leq b$ p.s. Alors

$$\mathbf{P}\left(\left|\sum_{i=1}^n (X_i - \mathbf{E}(X_i))\right| > \varepsilon\right) \leq 2e^{-\frac{3\varepsilon^2}{n(b-a)^2}}.$$

...

Concentration

...

Déterministe vs aléatoire

On se place dans le cadre de l'approximation de $\int_{[0;1]^d} \varphi(x) dx$ où $\varphi: [0;1]^d \rightarrow \mathbf{R}$.

Méthode déterministe des sommes de Riemann On se donne n^d points équidistants $(\frac{i_1}{n}, \dots, \frac{i_d}{n})$ où $(i_1, \dots, i_d) \in [1; n]^d$. La méthode des sommes de Riemann est

$$I_n(\varphi) = \frac{1}{n^d} \sum_{(i_1, \dots, i_d) \in [1; n]^d} \varphi\left(\frac{i_1}{n}, \dots, \frac{i_d}{n}\right).$$

Prop. Si $\varphi: [0;1]^d \rightarrow \mathbf{R}$ est L -lipschitzienne alors $|I_n(\varphi) - I(\varphi)| \leq L \frac{\sqrt{d}}{n}$.

...

3 Méthode des variables de contrôle

Présentation

Le contexte est maintenant comme Monte-Carlo avec une variable observée en plus :

- on observe $((X_1, \varphi(X_1), Y_1), \dots, (X_n, \varphi(X_n), Y_n))$ i.i.d,
- on cherche $\mathbf{E}[\varphi(X_1)]$,
- on connaît $\mathbf{E}[Y_1]$.

On peut calculer $\frac{1}{n} \sum_{i=1}^n [\varphi(X_i) - (Y_i - \mathbf{E}[Y_i])]$. C'est un estimateur sans biais de variance

$$\frac{1}{n} \text{Var}(\varphi(X_1) - (Y_1 - \mathbf{E}[Y_1])) = \frac{1}{n} \mathbf{E}[(\varphi(X_1) - (Y_1 - \mathbf{E}[Y_1]))^2] - \frac{1}{n} \mathbf{E}[\varphi(X_1)]^2.$$

Pour un tel estimateur, le but est de réduire ce risque L^2 au maximum en choisissant bien Y_1 . Pour un tel estimateur, on obtient facilement les mêmes résultats que pour Monte-Carlo : forte consistance, normalité asymptotique et estimation consistante de la variance.

Pour faciliter la notation on supposera maintenant $\mathbf{E}Y_1 = 0$.

Rem.

- $Y = 0 \rightarrow$ Monte-Carlo,
- $Y = \frac{-\varphi \circ L(X) - \varphi(X)}{2} \rightarrow$ variables antithétiques.

Rem. La méthode des variables de contrôle (VC) est plus performante que MC si $\text{Var}(\varphi(X_1) - Y_1) \leq \text{Var}(\varphi(X_1))$
 $(\frac{1}{n} \sum \varphi(X_i) + \frac{\varphi \circ L(X_i) - \varphi(X_i)}{2} = \frac{1}{2n} \sum \frac{\varphi(X_i) + \varphi \circ L(X_i)}{2})$.

Afin de prévenir d'une mauvaise variable de contrôle, on définit l'estimateur $\forall \beta \in \mathbf{R}, \hat{\mu}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta Y_i)$, à utiliser si $\text{Var}(\varphi(X_1) - \beta Y_1) \leq \text{Var}(\varphi(X_1))$.

$\rightarrow \beta^* = \arg \min_{\beta} \text{Var}(\varphi(X_1) - \beta Y_1), \min_{\beta} \text{Var}(\varphi - \beta Y) \leq \text{Var}(\varphi)$.

Soit f_1, \dots, f_m une collection de fonctions dont on connaît les intégrales. Supposons $\forall L \in [1; m], \int f_L d\lambda = 0$. Alors VC donne $\frac{1}{n} \sum_{i=1}^n [\varphi(u_i) - \sum_{j=1}^m \beta_j f_j(u_i)]$.

Ex. (f_L) polynômes, (f_L) base de Fourier ou (f_L) indicatrices.

Propriétés asymptotiques

Soient $((X_i, Y_i))_i$ une suite de v.a i.i.d à valeurs dans $S \times \mathbf{R}^m$. On définit l'estimateur de $\mathbf{E}[\varphi(X_1)]$ par $\forall \beta \in \mathbf{R}^m, \hat{\mu}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta^T Y_i)$.

Comme dans l'intro, on suppose $\mathbf{E}Y_1 = \begin{pmatrix} \mathbf{E}[Y_{1,1}] \\ \vdots \\ \mathbf{E}[Y_{1,m}] \end{pmatrix} = 0$.

$\{\mu_n(\beta), \beta \in \mathbf{R}^m\}$ est une collection d'estimateurs sans biais. Trouvons l'élément de variance minimale :

$$\begin{aligned} \beta^* &= \arg \min_{\beta} \frac{1}{n} \text{Var}(\varphi - \beta^T T) \\ &= \arg \min_{\beta} \text{Var}(\varphi - \beta^T T) \\ &= \arg \min_{\beta} \mathbf{E}[(\varphi - \beta^T Y)^2] - \mathbf{E}[\varphi]^2 \\ &= \arg \min_{\beta} \mathbf{E}[(\varphi - \beta^T Y)^2] \end{aligned}$$

Si $\mathbf{E}[Y_1 Y_1^T]$ est inversible, les équations normales / du premier ordre admettent une unique solution :

$$\beta^* = \mathbf{E}[Y_1 Y_1^T]^{-1} \mathbf{E}[Y_1 \varphi(X_1)]$$

Il faut utiliser $\hat{\mu}_n(\beta^*)$, mais β^* est inconnue.

Idée : estimer β^* sur les données $\rightarrow \hat{\beta}$, et utiliser $\hat{\mu}_n(\hat{\beta})$, qui a la même variance asymptotique que $\hat{\mu}_n(\beta^*)$.

Si $\frac{1}{n} \sum_{i=1}^n Y_i Y_i^T$ est inversible :

$$\hat{\beta} = \arg \min_{\beta \in \mathbf{R}^m} \frac{1}{n} \sum_{i=1}^n ([\varphi(X_i) - \beta^T Y_i] - \hat{\mu}_n(\beta))^2$$

estimateur classique de la covariance

Ce choix ne va pas entraîner de changement à l'asymptotique mais pratique il procure de meilleurs performances. Donc $\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n ((\varphi(X_i) - \bar{\varphi}) - \beta^T (Y_i - \bar{Y}))^2$.

Notons

$$Z_{n,m} = \begin{pmatrix} Y_{11} - \bar{Y}_1 & \cdots & Y_{1m} - \bar{Y}_m \\ \vdots & & \vdots \\ Y_{n1} - \bar{Y}_1 & \cdots & Y_{nm} - \bar{Y}_m \end{pmatrix} \in \mathbf{R}^{n \times m}, \quad Y_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{im} \end{pmatrix} \in \mathbf{R}^m$$

(Y_i est la covariable du problème de régression). On a $\bar{Y}_k = \frac{1}{n} \sum_{i=1}^n Y_{ik}$.

Notons également $\Psi_n = \begin{pmatrix} \varphi(X_1) - \bar{\varphi} \\ \vdots \\ \varphi(X_n) - \bar{\varphi} \end{pmatrix}$. Alors $\hat{\beta} = \arg \min_{\beta} \|\Psi_n - Z_{n,m} \beta\|^2$.

Le théorème de projection nous donne une unique solution qui, si $Z_{n,m}^T Z_{n,m}$ est inversible, vérifie :

$$(Z_{n,m}^T Z_{n,m}) \beta = Z_{n,m}^T \Psi_n$$

$$\hat{\beta} = (Z_{n,m}^T Z_{n,m})^{-1} Z_{n,m}^T \Psi_n$$

Prop (asymptotique de $\hat{\mu}_n(\beta)$). Supposons que $\mathbf{E}|\varphi(X_1)| < \infty$, $\forall k \in \llbracket 1; m \rrbracket$, $\mathbf{E}|\varphi(X_1)Y_{1k}| < \infty$ et $\mathbf{E}[Y_1 Y_1^T]$ existe et est inversible. Alors $\hat{\mu}_n(\hat{\beta}) \xrightarrow{p.s.} \mathbf{E}[\varphi(X_1)]$. Si de plus $\mathbf{E}|\varphi(X_1)|^2 < \infty$, alors $\sqrt{n}(\hat{\mu}_n(\hat{\beta}) - \mathbf{E}[\varphi(X_1)]) \rightarrow \mathcal{N}(0, \sigma_m^2)$ avec $\sigma_m^2 = \text{Var}(\varphi(X_1) - \beta^{*T} Y_1)$.

Rem. $\hat{\beta}$ n'a pas d'effet en l'asymptotique (c'est comme si on connaissait β^*).

Rem. D'autres estimateurs de β^* peuvent être légitimes sous condition d'inversibilité :

$$\hat{\beta} = \begin{cases} \left(\frac{1}{n} \sum Y_i Y_i^T \right)^{-1} \frac{1}{n} \sum Y_i \varphi(X_i) \\ \left(\frac{1}{n} \sum (Y_i - \bar{Y})(Y_i - \bar{Y})^T \right)^{-1} \frac{1}{n} \sum Y_i \varphi(X_i) \end{cases}$$

Lorsque $\mathbf{E}[Y_1 Y_1^T]$ est connu, $\hat{\beta} = \mathbf{E}[Y_1 Y_1^T]^{-1} \frac{1}{n} \sum_{i=1}^n (Y_i(\varphi(X_i) - \bar{\varphi}))$.

...

Temps de calcul

Soit F une c.d.f sur \mathbf{R} et $\varphi: \mathbf{R} \rightarrow \mathbf{R}$. On veut calculer $\mathbf{E}_F[\varphi]$.

Le nombre d'échantillons n'est pas fixé par le problème initial. Il est donc à déterminer par rapport à la précision souhaitée et le temps de calcul dont on dispose.

Données massives \rightarrow la problématique du temps de calcul est redevenue essentielle aujourd'hui.

Mesure du temps \rightarrow par simulation, en terme d'opérations élémentaires.

Règles du temps de calcul (peuvent changer selon le problème) :

- générer $X_1 \rightarrow 1$ opération élémentaire,
- générer $Y_{1,k}$ pour chaque $k \rightarrow 1$ opération élémentaire,
- évaluer $\varphi(X_1) \rightarrow 1$ opération élémentaire.

MC	nombre d'opérations élémentaires
X_1, \dots, X_n	n
$\varphi(X_1), \dots, \varphi(X_n)$	n
$\frac{1}{n} \sum_{i=1}^n \varphi(X_i)$	$\sim n$
	$O(n)$
VC	nombre d'opérations élémentaires
X_1, \dots, X_n	n
$\varphi(X_1), \dots, \varphi(X_n)$	n
Y_1, \dots, Y_n	mn
$\frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta^T Y_i)$	mn
	$O(mn)$
$\hat{\beta}$	nombre d'opérations élémentaires
...	...
...	...
...
	$O(m^3 + m^2 n)$