

MACS205 : Méthode de Monte-Carlo

1 Introduction

But du cours : étudier des méthodes aléatoires d'approximation d'intégrales.

Soit (S, \mathcal{S}, μ) un espace mesuré où μ est une mesure positive. Soit $\varphi: S \rightarrow \mathbf{R}$ une fonction intégrable. On cherche à approcher $I(\varphi) = \int \varphi d\mu$.

Plusieurs cas de figure en pratique :

- φ est une fonction continue avec une expression analytique et on arrive à calculer son intégrale,
- l'intégrale de φ est incalculable. Exemples : Gaussienne ou indicatrice d'ensemble S où l'on ne connaît pas de forme analytique.

Les méthodes considérées sont de la forme suivante :

1. choisir/tirer des points X_1, \dots, X_n sur S ,
2. évaluer $\varphi(X_1), \dots, \varphi(X_n)$,
3. trouver une transformation de $(X_1, \varphi(X_1)), \dots, (X_n, \varphi(X_n))$ qui approche $I(\varphi)$.

2 La méthode de Monte-Carlo

$$I(\varphi) = \int \varphi dN = \mathbf{E}_\mu(\varphi)$$

D'après la LFGN, si X_1, \dots, X_n sont i.i.d. de loi μ tel que $\mathbf{E}_\mu |vf| < \infty$ alors $\frac{1}{n} \sum_i \varphi(X_i) \xrightarrow{\text{p.s.}} \mathbf{E}_\mu(\varphi(X_1))$.

Algorithme 1 : Monte-Carlo

Générer X_1, \dots, X_n de façon indépendante sous μ ;

Calculer $\varphi(X_1), \dots, \varphi(X_n)$;

Sorties : $\hat{I}_n(\varphi) = \frac{1}{n} \sum_i \varphi(X_i)$

Prop. Si $\int |\varphi| d\mu < \infty$, $\hat{I}_n(\varphi)$ est non-biaisée et consistante. Si $\int |\varphi|^2 d\mu < \infty$, $\text{Var}(\hat{I}_n(\varphi)) = \frac{1}{n} \text{Var}(\varphi(X_1)) = \frac{1}{n} \sigma^2$ et $\sqrt{n}(\hat{I}_n(\varphi) - I(\varphi)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

On estime σ^2 par $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (\varphi(X_i) - \hat{I}_n(\varphi))^2$.

Prop. Si $\int |\varphi|^2 d\mu < \infty$ alors $\hat{\sigma}^2$ est sans biais et fortement consistant (par la LFGN).

...

Th (Inégalité de Hoeffding). Soit (X_1, \dots, X_n) des v.a i.i.d telles que $\forall i \in [1; n], a \leq X_i \leq b$ p.s. Alors

$$\mathbf{P}\left(\left|\sum_{i=1}^n (X_i - \mathbf{E}(X_i))\right| > \varepsilon\right) \leq 2e^{-\frac{3\varepsilon^2}{n(b-a)^2}}.$$

...

Concentration

...

Déterministe vs aléatoire

On se place dans le cadre de l'approximation de $\int_{[0;1]^d} \varphi(x) dx$ où $\varphi: [0;1]^d \rightarrow \mathbf{R}$.

Méthode déterministe des sommes de Riemann On se donne n^d points équidistants $(\frac{i_1}{n}, \dots, \frac{i_d}{n})$ où $(i_1, \dots, i_d) \in [1; n]^d$. La méthode des sommes de Riemann est

$$I_n(\varphi) = \frac{1}{n^d} \sum_{(i_1, \dots, i_d) \in [1; n]^d} \varphi\left(\frac{i_1}{n}, \dots, \frac{i_d}{n}\right).$$

Prop. Si $\varphi: [0;1]^d \rightarrow \mathbf{R}$ est L -lipschitzienne alors $|I_n(\varphi) - I(\varphi)| \leq L \frac{\sqrt{d}}{n}$.

...

3 Méthode des variables de contrôle

Présentation

Le contexte est maintenant comme Monte-Carlo avec une variable observée en plus :

- on observe $((X_1, \varphi(X_1), Y_1), \dots, (X_n, \varphi(X_n), Y_n))$ i.i.d,
- on cherche $\mathbf{E}[\varphi(X_1)]$,
- on connaît $\mathbf{E}[Y_1]$.

On peut calculer $\frac{1}{n} \sum_{i=1}^n [\varphi(X_i) - (Y_i - \mathbf{E}[Y_i])]$. C'est un estimateur sans biais de variance

$$\frac{1}{n} \text{Var}(\varphi(X_1) - (Y_1 - \mathbf{E}[Y_1])) = \frac{1}{n} \mathbf{E}[(\varphi(X_1) - (Y_1 - \mathbf{E}[Y_1]))^2] - \frac{1}{n} \mathbf{E}[\varphi(X_1)]^2.$$

Pour un tel estimateur, le but est de réduire ce risque L^2 au maximum en choisissant bien Y_1 . Pour un tel estimateur, on obtient facilement les mêmes résultats que pour Monte-Carlo : forte consistance, normalité asymptotique et estimation consistante de la variance.

Pour faciliter la notation on supposera maintenant $\mathbf{E}Y_1 = 0$.

Rem.

- $Y = 0 \rightarrow$ Monte-Carlo,
- $Y = \frac{-\varphi \circ L(X) - \varphi(X)}{2} \rightarrow$ variables antithétiques.

Rem. La méthode des variables de contrôle (VC) est plus performante que MC si $\text{Var}(\varphi(X_1) - Y_1) \leq \text{Var}(\varphi(X_1))$
 $(\frac{1}{n} \sum \varphi(X_i) + \frac{\varphi \circ L(X_i) - \varphi(X_i)}{2} = \frac{1}{2n} \sum \frac{\varphi(X_i) + \varphi \circ L(X_i)}{2}).$

Afin de prévenir d'une mauvaise variable de contrôle, on définit l'estimateur $\forall \beta \in \mathbf{R}, \hat{\mu}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta Y_i)$, à utiliser si $\text{Var}(\varphi(X_1) - \beta Y_1) \leq \text{Var}(\varphi(X_1))$.

$\rightarrow \beta^* = \arg \min_{\beta} \text{Var}(\varphi(X_1) - \beta Y_1), \min_{\beta} \text{Var}(\varphi - \beta Y) \leq \text{Var}(\varphi).$

Soit f_1, \dots, f_m une collection de fonctions dont on connaît les intégrales. Supposons $\forall L \in [1; m], \int f_L d\lambda = 0$. Alors VC donne $\frac{1}{n} \sum_{i=1}^n [\varphi(u_i) - \sum_{j=1}^m \beta_j f_j(u_i)]$.

Ex. (f_L) polynômes, (f_L) base de Fourier ou (f_L) indicatrices.

Propriétés asymptotiques

Soient $((X_i, Y_i))_i$ une suite de v.a i.i.d à valeurs dans $S \times \mathbf{R}^m$. On définit l'estimateur de $\mathbf{E}[\varphi(X_1)]$ par $\forall \beta \in \mathbf{R}^m, \hat{\mu}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta^T Y_i)$.

Comme dans l'intro, on suppose $\mathbf{E}Y_1 = \begin{pmatrix} \mathbf{E}[Y_{1,1}] \\ \vdots \\ \mathbf{E}[Y_{1,m}] \end{pmatrix} = 0$.

$\{\mu_n(\beta), \beta \in \mathbf{R}^m\}$ est une collection d'estimateurs sans biais. Trouvons l'élément de variance minimale :

$$\begin{aligned} \beta^* &= \arg \min_{\beta} \frac{1}{n} \text{Var}(\varphi - \beta^T T) \\ &= \arg \min_{\beta} \text{Var}(\varphi - \beta^T T) \\ &= \arg \min_{\beta} \mathbf{E}[(\varphi - \beta^T Y)^2] - \mathbf{E}[\varphi]^2 \\ &= \arg \min_{\beta} \mathbf{E}[(\varphi - \beta^T Y)^2] \end{aligned}$$

Si $\mathbf{E}[Y_1 Y_1^T]$ est inversible, les équations normales / du premier ordre admettent une unique solution :

$$\beta^* = \mathbf{E}[Y_1 Y_1^T]^{-1} \mathbf{E}[Y_1 \varphi(X_1)]$$

Il faut utiliser $\hat{\mu}_n(\beta^*)$, mais β^* est inconnue.

Idée : estimer β^* sur les données $\rightarrow \hat{\beta}$, et utiliser $\hat{\mu}_n(\hat{\beta})$, qui a la même variance asymptotique que $\hat{\mu}_n(\beta^*)$.

Si $\frac{1}{n} \sum_{i=1}^n Y_i Y_i^T$ est inversible :

$$\hat{\beta} = \arg \min_{\beta \in \mathbf{R}^m} \frac{1}{n} \sum_{i=1}^n ([\varphi(X_i) - \beta^T Y_i] - \hat{\mu}_n(\beta))^2$$

estimateur classique de la covariance

Ce choix ne va pas entraîner de changement à l'asymptotique mais pratique il procure de meilleurs performances. Donc $\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n ((\varphi(X_i) - \bar{\varphi}) - \beta^T (Y_i - \bar{Y}))^2$.

Notons

$$Z_{n,m} = \begin{pmatrix} Y_{11} - \bar{Y}_1 & \cdots & Y_{1m} - \bar{Y}_m \\ \vdots & & \vdots \\ Y_{n1} - \bar{Y}_1 & \cdots & Y_{nm} - \bar{Y}_m \end{pmatrix} \in \mathbf{R}^{n \times m}, \quad Y_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{im} \end{pmatrix} \in \mathbf{R}^m$$

(Y_i est la covariable du problème de régression). On a $\bar{Y}_k = \frac{1}{n} \sum_{i=1}^n Y_{ik}$.

Notons également $\Psi_n = \begin{pmatrix} \varphi(X_1) - \bar{\varphi} \\ \vdots \\ \varphi(X_n) - \bar{\varphi} \end{pmatrix}$. Alors $\hat{\beta} = \arg \min_{\beta} \|\Psi_n - Z_{n,m} \beta\|^2$.

Le théorème de projection nous donne une unique solution qui, si $Z_{n,m}^\top Z_{n,m}$ est inversible, vérifie :

$$(Z_{n,m}^\top Z_{n,m}) \beta = Z_{n,m}^\top \Psi_n$$

$$\hat{\beta} = (Z_{n,m}^\top Z_{n,m})^{-1} Z_{n,m}^\top \Psi_n$$

Prop (asymptotique de $\hat{\mu}_n(\beta)$). Supposons que $\mathbf{E}|\varphi(X_1)| < \infty$, $\forall k \in \llbracket 1 ; m \rrbracket$, $\mathbf{E}|\varphi(X_1)Y_{1k}| < \infty$ et $\mathbf{E}[Y_1 Y_1^\top]$ existe et est inversible. Alors $\hat{\mu}_n(\hat{\beta}) \xrightarrow{\text{p.s.}} \mathbf{E}[\varphi(X_1)]$. Si de plus $\mathbf{E}|\varphi(X_1)|^2 < \infty$, alors $\sqrt{n}(\hat{\mu}_n(\hat{\beta}) - \mathbf{E}[\varphi(X_1)]) \longrightarrow \mathcal{N}(0, \sigma_m^2)$ avec $\sigma_m^2 = \text{Var}(\varphi(X_1) - \beta^{*\top} Y_1)$.

