

# MACS205 : Méthode de Monte-Carlo

## 1 Introduction

Soit  $(S, \mathcal{S}, \mu)$  un espace mesuré où  $\mu$  est une mesure positive. Soit  $\varphi: S \rightarrow \mathbf{R}$  une fonction intégrable. On cherche à approcher  $I(\varphi) = \int \varphi d\mu = \mathbf{E}_\mu(\varphi)$ . Deux cas de figure :

- $\varphi$  est une fonction continue avec une expression analytique et on arrive à calculer son intégrale,
- l'intégrale de  $\varphi$  est incalculable.

Les méthodes de type Monte-Carlo considérées sont de la forme suivante :

1. tirer aléatoirement des points  $X_1, \dots, X_n$  sur  $S$ ,
2. calculer  $\varphi(X_1), \dots, \varphi(X_n)$ ,
3. trouver une transformation de  $(X_1, \varphi(X_1)), \dots, (X_n, \varphi(X_n))$  qui approche  $I(\varphi)$ .

## 2 La méthode de Monte-Carlo

### Algorithme 1 : Monte-Carlo

Générer  $X_1, \dots, X_n$  de façon indépendante sous  $\mu$  ;  
Calculer  $\varphi(X_1), \dots, \varphi(X_n)$  ;

**Sorties :**  $\hat{I}_n(\varphi) = \hat{I}_n^{(mc)}(\varphi) = \frac{1}{n} \sum_i \varphi(X_i)$

**Prop.** Si  $\int |\varphi| d\mu < \infty$ ,  $\hat{I}_n(\varphi)$  est non-biaisée et fortement consistante. Si de plus  $\int |\varphi|^2 d\mu < \infty$  alors  $\text{Var}(\hat{I}_n(\varphi)) = \frac{1}{n} \text{Var}(\varphi(X_1)) = \frac{1}{n} \sigma^2$  et  $\sqrt{n}(\hat{I}_n(\varphi) - I(\varphi)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$ .

### Estimation de l'erreur

On estime  $\sigma^2$  par  $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (\varphi(X_i) - \hat{I}_n(\varphi))^2$ .

**Prop.** Si  $\int |\varphi|^2 d\mu < \infty$  alors  $\hat{\sigma}^2$  est sans biais et fortement consistant et  $\frac{\sqrt{n}}{\hat{\sigma}} (\hat{I}_n(\varphi) - I(\varphi)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$ .

Intervalle de confiance :  $\mathbf{P}(I(\varphi) \in \hat{C}(\alpha)) \xrightarrow{n \rightarrow \infty} 1 - \alpha$  avec  $\forall \alpha \in ]0; 1[, \hat{C}(\alpha) = \left[ \hat{I}_n(\varphi) - \frac{\hat{\sigma}^2}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \hat{I}_n(\varphi) + \frac{\hat{\sigma}^2}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \right]$ .

### Inégalités de concentrations

**Th** (Inégalité de Hoeffding). Soit  $X_1, \dots, X_n$  i.i.d telles que  $\forall i \in \llbracket 1; n \rrbracket, a \leq X_i \leq b$  p.s. Alors

$$\mathbf{P}\left(\left|\sum_{i=1}^n (X_i - \mathbf{E}(X_i))\right| > \varepsilon\right) \leq 2 \cdot \exp\left(-\frac{2\varepsilon^2}{n(b-a)^2}\right).$$

### Déterministe vs aléatoire en "grande" dimension

Méthode déterministe des sommes de Riemann : soit  $\varphi: [0; 1]^d \rightarrow \mathbf{R}$ , on se donne  $n^d$  points équidistants  $x_\alpha = \left(\frac{i_1}{n}, \dots, \frac{i_d}{n}\right)$  où  $(i_1, \dots, i_d) \in \llbracket 1; n \rrbracket^d$ . On calcule  $I_n^{(rs)}(\varphi) = \frac{1}{n^d} \sum \varphi(x_\alpha)$ .

**Prop.** Si  $\varphi: [0; 1]^d \rightarrow \mathbf{R}$  est  $L$ -lipschitzienne alors  $\left|I_n^{(rs)}(\varphi) - I(\varphi)\right| \leq L \frac{\sqrt{d}}{n}$ .

Avec Monte-Carlo la méthode de même ordre se fait avec évaluation en  $n^d$  v.a tirées selon  $\mathcal{U}([0; 1]^d)$  et l'on a  $\text{Var}(\hat{I}_{n^d}(\varphi)) = \frac{1}{n^d} \sigma^2$  et  $\mathbf{E}\left[\left|\hat{I}_{n^d}(\varphi) - I(\varphi)\right|\right] \leq \frac{\sigma}{n^{d/2}}$ .

## Méthode des variables antithétiques

Soit  $Z \sim \mu$  v.a telle que  $\mathbf{E}[\varphi(Z)^2] < \infty$  et  $\{Z_k, k \geq 0\}$  i.i.d selon  $\mu$ . On a  $\hat{I}_n^{(av)}(\varphi) = \frac{1}{2n} \sum_{i=1}^n (\varphi(Z_i) + \varphi(L(Z_i)))$ .

**Ex.**  $U_1, \dots, U_n \sim \mathcal{U}([a; b])$  et  $L(u) := a + b - u$ , ou si  $Z \sim \mathcal{N}(\mu, 1)$  alors  $2\mu - Z \sim \mathcal{N}(\mu, 1)$ .

**Prop.** Si  $\mathbf{E}|\varphi(Z)|^2 < \infty$  alors :

- $\text{Var}(\hat{I}_{2n}^{(av)}(\varphi)) \geq \text{Var}(\hat{I}_n^{(av)}) \iff \text{Cov}(\varphi(Z), \varphi(L(Z))) \leq 0$ ,
- si  $\varphi$  est réelle croissante et  $\varphi \circ L$  décroissante (ou inversement) alors  $\text{Cov}(\varphi(Z), \varphi(L(Z))) \leq 0$ .

**Lem.** Soit  $Z$  une v.a réelle,  $g: \mathbf{R} \rightarrow \mathbf{R}$  croissante avec  $\mathbf{E}[g(Z)^2] < \infty$  et  $\tilde{g}: \mathbf{R} \rightarrow \mathbf{R}$  décroissante avec  $\mathbf{E}[\tilde{g}(Z)^2] < \infty$ . Alors  $\text{Cov}(g(Z), \tilde{g}(Z)) \leq 0$ .

## 3 Méthode des variables de contrôle

Le contexte est comme Monte-Carlo avec une variable observée en plus :  $((X_1, Z_1), \dots, (X_n, Z_n))$  i.i.d dans  $S \times \mathbf{R}$ ,  $X_1 \sim \mu$  et  $\mathbf{E}[Z_1]$  est connu. Soit  $\varphi: S \rightarrow \mathbf{R}$  tel que  $\mathbf{E}|\varphi(X_1)| < \infty$ , on cherche  $I_\mu = \mathbf{E}[\varphi(X_1)]$ .

On peut se ramener à  $\mathbf{E}Z_1 = 0$ , et on pose  $\hat{I}_n^{(cv)} = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - Z_i)$ .

**Prop.** Si  $\mathbf{E}|\varphi(X_1)| < \infty$  et  $\mathbf{E}|Z_1| < \infty$ ,  $\hat{I}_n^{(cv)}$  est sans biais et fortement consistant. Si de plus  $\mathbf{E}|\varphi(X_1)|^2 < \infty$  et  $\mathbf{E}|Z_1|^2 < \infty$  alors :

- $\text{Var}(\hat{I}_n^{(cv)}) = \frac{1}{n} \text{Var}(\varphi(X_1) - Z_1)$  et  $\hat{I}_n^{(cv)}$  est asymptotiquement normal avec variance  $\sigma^2 = \text{Var}(\varphi(X_1) - Z_1)$ , i.e  $\sqrt{n}(\hat{I}_n^{(cv)} - I) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$ ,
- un estimateur consistant de  $\sigma^2$  est  $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n ((\varphi(X_i) - Z_i) - \hat{I}_n^{(cv)})^2$ .

**Rem.** Cela comprend Monte-Carlo :  $Z_1 = 0$ , et les variables antithétiques :  $Z_1 = \frac{1}{2}(\varphi(X_1) - (\varphi \circ L)(X_1))$ .

**Rem.** VC est plus performante que MC si  $\text{Var}(\varphi(X_1) - Z_1) \leq \text{Var}(\varphi(X_1))$ .

Pour prévenir d'une mauvaise variable de contrôle, on définit l'estimateur  $\frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta Z_i)$ , à utiliser si  $\text{Var}(\varphi(X_1) - \beta Z_1) \leq \text{Var}(\varphi(X_1))$ . C'est vérifié avec  $\beta^* = \arg \min_{\beta} \text{Var}(\varphi(X_1) - \beta Z_1) = \mathbf{E}[\varphi(X_1)Z_1] / \mathbf{E}[Z_1^2]$ .

**Propriétés asymptotiques :**  $Z_1 \in \mathbf{R}^m$

On estime  $I = \mathbf{E}[\varphi(X_1)]$  par  $\hat{I}_n^{(cv)}(\beta) = \frac{1}{n} \sum_{i=1}^n (\varphi(X_i) - \beta^\top Z_i)$  où  $\beta \in \mathbf{R}^m$ , avec encore  $\mathbf{E}Z_1 = 0$ .

La valeur théorique pour minimiser la variance, si  $\mathbf{E}[Z_1 Z_1^\top]$  est inversible, est  $\beta^* = \mathbf{E}[Z_1 Z_1^\top]^{-1} \mathbf{E}[Z_1 \varphi(X_1)]$ .

En pratique on l'estime. Notons  $Z_{n,m} = (Z_1 \dots Z_n)^\top \in \mathbf{R}^{n \times m}$ , et  $\varphi_i = (\varphi(X_1), \dots, \varphi(X_n))^\top \in \mathbf{R}^n$ .

Alors  $\hat{\beta}_n = (Z_{n,m}^\top Z_{n,m})^+ Z_{n,m}^\top \varphi_n = \left(\frac{1}{n} \sum Z_i Z_i^\top\right)^{-1} \frac{1}{n} \sum Z_i \varphi(X_i)$  (en notant  $A^+$  l'inverse généralisé de  $A$ ).

**Prop.** Supposons  $\mathbf{E}|\varphi(X_1)| < \infty$ ,  $\forall k \in [1; m], \mathbf{E}|\varphi(X_1)Z_{k,1}| < \infty$  et  $\mathbf{E}[Z_1 Z_1^\top]$  existe et est inversible. Alors  $\hat{I}_n^{(cv)}(\hat{\beta}_n) \xrightarrow{\text{p.s.}} I$  (fortement consistant). Si de plus  $\mathbf{E}|\varphi(X_1)|^2 < \infty$ , alors  $\sqrt{n}(\hat{I}_n^{(cv)}(\hat{\beta}_n) - I) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_m^2)$  avec  $\sigma_m^2 = \text{Var}(\varphi(X_1) - \beta^{*\top} Z_1)$ .

**Rem.** L'estimation de  $\hat{\beta}_n$  n'a pas d'effet en l'asymptotique (c'est comme si on connaissait  $\beta^*$ ).

**Rem.** D'autres estimateurs de  $\beta^*$  peuvent être légitimes sous condition d'inversibilité et de consistance.

**Rem.** On a  $\forall m \geq 0, \sigma_{m+1} \leq \sigma_m$  et  $\sigma_0^2$  correspond à la variance de Monte-Carlo. Un estimateur de la variance de  $\hat{I}_n^{(cv)}(\hat{\beta}_n)$  est donné par  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \left( \varphi(X_i) - \hat{\beta}_n^\top Z_i - \hat{I}_n^{(cv)}(\hat{\beta}_n) \right)^2$ .

**Prop.** Supposons  $\mathbb{E}|\varphi(X_1)|^2 < \infty, \forall k \in \llbracket 1; m \rrbracket, \mathbb{E}|\varphi(X_1)Z_{k,1}| < \infty$  et  $\mathbb{E}[Z_1 Z_1^\top]$  est inversible. Alors  $\hat{\sigma}^2 \xrightarrow[n \rightarrow \infty]{} \sigma_m^2$ .

### Complexité du calcul

Règles du temps de calcul : générer  $X_1$ , générer  $Z_{1,k}$  pour un  $k$  et évaluer  $\varphi(X_1)$  comptent chacun pour une opération élémentaire.

Méthode	Nombre d'opérations élémentaires
Monte Carlo	$O(n)$
Calcul de $\hat{\beta}_n$	$O(m^2 n + m^3)$
Variables de contrôle (avec $\hat{\beta}_n$ donné)	$O(mn)$

Donc la méthode avec variable de contrôle est mieux que Monte Carlo lorsque  $\frac{\sigma_m}{\sigma_0} \leq \frac{1}{m}$ .

## 4 Échantillonnage préférentiel

Contexte : estimation de  $I_\lambda = \int \varphi d\lambda$  où  $\varphi : S \rightarrow \mathbf{R}$  est intégrable et  $S \subseteq \mathbf{R}^d$ .

**Def.** Si  $g : \mathbf{R}^d \rightarrow \mathbf{R}$ , on définit son support comme l'ensemble fermé  $S_g = \overline{\{x \in \mathbf{R}^d \mid g(x) \neq 0\}}$ .

L'échantillonnage d'importance se base sur la formule suivante : pour toute densité  $f$  telle que  $S_f \supset S_\varphi$ ,

$$I_\lambda = \int_{S_\varphi} \varphi(x) dx = \int_{S_f} \varphi(x) dx = \int_{S_f} \frac{\varphi(x)}{f(x)} f(x) dx = \mathbb{E}_{X \sim f} \left[ \frac{\varphi(X)}{f(X)} \right]$$

L'échantillonnage d'importance "naïf" consiste à générer  $X_1, \dots, X_n \sim f$  i.i.d puis appliquer Monte-Carlo :

$$\hat{I}_n^{(is)} = \frac{1}{n} \sum_{i=1}^n \frac{\varphi(X_i)}{f(X_i)}.$$

La distribution associée à  $f$  est appelée **distribution d'échantillonnage**, ou bien l'**échantillonneur**.

**Prop.** Si  $\int |\varphi| < \infty$  et  $S_\varphi \subseteq S_f, \hat{I}_n^{(is)} \xrightarrow{\text{p.s.}} I_\lambda$ . Si de plus  $\int \frac{\varphi^2(x)}{f(x)} dx < \infty$  alors :

- $\sqrt{n}(\hat{I}_n^{(is)} - I_\lambda) \xrightarrow{\mathcal{L}} \mathcal{N}(0, r_f^2(\varphi))$  avec  $r_f^2(\varphi) = \text{Var}\left(\frac{\varphi}{f}\right) = \int \left(\frac{\varphi(x)}{f(x)} - I_\lambda\right)^2 f(x) dx$
- $\frac{\sqrt{n}}{\hat{r}_n}(\hat{I}_n^{(is)} - I_\lambda) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$  avec  $\hat{r}_n^2 = \frac{1}{n} \sum \left(\frac{\varphi(X_i)}{f(X_i)} - \hat{I}_n^{(is)}\right)^2$  l'estimateur de la variance.

Cette méthode est naïve car  $f$  n'est pas choisie par rapport à  $\varphi$ .

**Rem.** Si on cherche  $\mathbb{E}[\varphi(Z)]$  où  $Z \sim g$ , alors prendre  $g \cdot \varphi$  à la place de  $\varphi$ .

Par ailleurs il existe deux méthodes de réduction de la variance où l'on s'adapte à  $\varphi$  :

- variable de contrôle : approcher  $\varphi$  dans une certaine base  $\rightarrow$  pas de choix d'échantillonneur,
- changer la mesure d'échantillonnage.

### Réduction de la variance

On remarque que  $r_f^2(\varphi) = 0 \iff \varphi/f \equiv I_\lambda$ .

**Th.** Si  $\int |\varphi| < \infty$ , alors parmi les densités  $f$  telle que  $\int \frac{\varphi^2}{f} d\lambda < \infty$ , i.e.  $S_\varphi \subseteq S_f$ , le minimiseur de  $r_f^2(\varphi)$  est unique et donné par  $f^* = \frac{|\varphi|}{\int |\varphi| d\lambda}$ . La variance associée est  $r_{f^*}^2(\varphi) = \left(\int |\varphi| d\lambda\right)^2 - \left(\int \varphi d\lambda\right)^2$ .

## Échantillonnage préférentiel paramétrique

On se donne une famille paramétrique  $\mathcal{F} = \{f_\theta, \theta \in \Theta\}$  de densités par rapport à la mesure de Lebesgue pour lesquelles on sait générer des v.a, avec  $\Theta \subset \mathbf{R}^q, q \geq 1$ . On suppose  $\forall \theta \in \Theta, S_\varphi \subseteq S_{f_\theta}$ .

Soit  $\theta^* \in \arg \min_{\theta \in \Theta} r_{f_\theta}^2(\varphi) = \arg \min_{\theta \in \Theta} \int \frac{\varphi^2}{f_\theta} d\lambda$ . On cherche à estimer par simulation cette variance. On utilise l'algorithme suivant, avec en entrée  $n \in \mathbf{N}^*$ ,  $\mathcal{F}$  et  $f_0$  l'échantillon initial.

- (i) Soit  $n_1 < n$  et  $n_2 = n - n_1$ . Générer  $X_1, \dots, X_{n_1} \sim f_0$  i.i.d.
- (ii) Calculer  $\hat{\theta}_{n_1}^{(1)} = \arg \min_{\theta \in \Theta} \hat{\psi}_{n_1}^{(1)}(\theta)$  où  $\hat{\psi}_{n_1}^{(1)}(\theta) := \frac{1}{n_1} \sum_{i=1}^{n_1} \frac{\varphi(X_i)^2}{f_\theta(X_i)f_0(X_i)}$ .
- (iii) Générer  $Z_1, \dots, Z_{n_2} \sim f_{\hat{\theta}_{n_1}^{(1)}}$ .
- (iv) Calculer  $\frac{1}{n_2} \sum_{i=1}^{n_2} \frac{\varphi(Z_i)}{f_{\hat{\theta}_{n_1}^{(1)}}(Z_i)}$  ou  $\frac{1}{n} \left( \sum_{i=1}^{n_1} \frac{\varphi(X_i)}{f_0(X_i)} + \sum_{i=1}^{n_2} \frac{\varphi(Z_i)}{f_{\hat{\theta}_{n_1}^{(1)}}(Z_i)} \right)$ .

On peut aussi utiliser la méthode par vraisemblance où l'on remplace  $\hat{\psi}_{n_1}^{(1)}$  par  $\hat{\psi}_{n_1}^{(2)}: \theta \mapsto \frac{1}{n_1} \sum_{i=1}^{n_1} \ln \left( \frac{f_\theta(X_i)}{f_0(X_i)} \right) \frac{|\varphi(X_i)|}{f_0(X_i)}$ . On appelle  $\hat{I}_{n,1}^{(is)}$  et  $\hat{I}_{n,2}^{(is)}$  les deux estimateurs obtenus.

**Lem.** Supposons  $\Theta$  compact,  $\psi$  continue sur  $\Theta$ , qu'il existe un unique  $\theta^* \in \arg \min_{\theta \in \Theta} \psi(\theta)$ , que  $\sup_{\theta \in \Theta} |\hat{\psi}(\theta) - \psi(\theta)| \xrightarrow[n]{P} 0$  et que  $\hat{\theta}_{n_1}$  minimise  $\hat{\psi}$ . Alors  $|\hat{\theta}_{n_1} - \theta^*| \xrightarrow[n_1]{P} 0$ .

**Prop.**  $\hat{I}_{n,1}^{(is)}$  et  $\hat{I}_{n,2}^{(is)}$  sont des estimateurs sans biais de  $I_\lambda$ .

**Prop.** Soit  $v_0 = \text{Var} \left( \frac{\varphi(X_1)}{f_0(X_1)} \right)$ . Supposons  $v_0 < \infty$  et  $\sup_{\theta \in \Theta} \int \frac{\varphi(x)^2}{f_\theta(x)} dx < \infty$ . Alors on a  $\text{Var} \left( \hat{I}_{n,1}^{(is)} \right) = \frac{1}{n_2} \left( \mathbf{E}[\psi^{(1)}(\hat{\theta}_{n_1})] - I_\lambda^2 \right)$  et  $\text{Var} \left( \hat{I}_{n,2}^{(is)} \right) = \frac{1}{n^2} \left[ n_1 v_0 + n_2 \left( \mathbf{E}[\psi^{(1)}(\hat{\theta}_{n_1})] - I_\lambda^2 \right) \right]$ .

La complexité est en  $O(n + n_1^2 + n_2) = O(n)$ .